

Latar Belakang




Kehilangan **pelanggan yang beralih ke bank lain** akibat persaingan tinggi, perubahan preferensi konsumen, dan kemajuan teknologi.



CRM menempatkan pelanggan sebagai pusat kegiatan bisnis dan kesuksesan perusahaan bergantung pada pengelolaan hubungan yang efektif.

Manfaat Teknologi



Otomatisasi berguna untuk mengurangi waktu dan tenaga melalui otomatisasi tugas

Teknologi dapat digunakan sebagai **pengambilan keputusan cepat** dengan data *real-time*.

Tujuan Proyek

1. Mengenali pelanggan yang kemungkinan akan beralih ke layanan bank dari pesaing?
2. Meningkatkan cara kita memvisualisasikan data agar lebih mudah dipahami?

Data


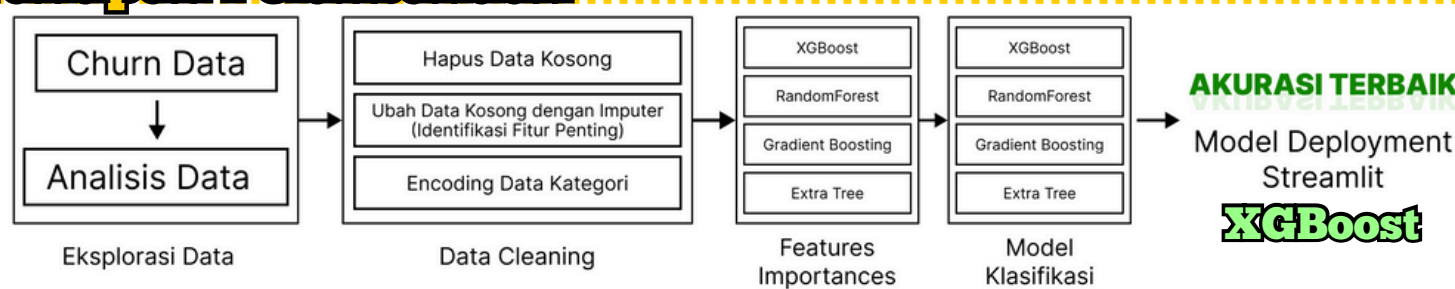
Data diperoleh dari Kaggle "**Customer Churn**"

Data memiliki **23 Kolom** sebanyak **10127 Data** { **80% Train** **20% Test**

Machine Learning


Membandingkan Algoritma Random Forest **XGBoost*** Extra Tree Gradient Boosting

Tahapan Pelaksanaan



Aplikasi Streamlit


Visualisasi Data



Hasil

Projek Streamlit
bankchurnpredict.streamlit.app

Features Importance



Features Importance berfungsi untuk **mengurangi jumlah fitur** yang digunakan pada proses training. Hasil ideal yang didapatkan adalah peningkatan akurasi model.

Evaluasi Model

Classifier	Extra Trees	XBoost	Gradient Boosting	Random Forest	No Features Importance
Gradient Boosting Classifier	89,50	90,91	94,53	94,53	98,21
Random Forest Classifier	90,88	91,79	95,44	95,32	97,53
Extra Trees Classifier	85,71	87,24	91,97	92,18	91,85
XGBoost Classifier	90,26	92,30	95,56	95,68	98,56

= Model Klasifikasi dengan Perolehan Akurasi Terbaik
 = Hubungan Importance Features dengan Perolehan Akurasi Terbaik
 = Model Terbaik

Penggunaan **features importance** pada algoritma random forest dan gradient boosting **meningkatkan akurasi sebesar 5%**. Sehingga algoritma features importance memang benar dapat meningkatkan akurasi. **Model terbaik** untuk implementasi aplikasi berbasis Streamlit adalah **XGBoost** dengan **akurasi 98,56% tanpa pemilihan fitur tertentu**.

Kesimpulan

Setelah **perbandingan metode** yang telah kami lakukan, kami menemukan bahwa **XGBoost** adalah metode yang **paling efektif** dan **penggunaan feature importance** telah **terbukti meningkatkan akurasi** dalam beberapa kasus, walaupun kami memutuskan untuk tidak menggunakannya untuk studi kasus deteksi *churn*. Selain itu, **visualisasi data** telah terbukti menjadi alat yang **sangat berguna dalam analisis** dan **prediksi churn pelanggan**. Visualisasi tidak hanya memberikan wawasan yang mendalam tetapi juga mempermudah komunikasi hasil analisis, yang pada akhirnya membantu dalam **meningkatkan performa model** dan **pengambilan keputusan strategis**.

Referensi

- [1] Wibowo, A. S., dan R. Rusdianto, "Analisis Churn Nasabah Bank Dengan Pendekatan Machine Learning dan Pengelompokan Profil Nasabah dengan Pendekatan Clustering," *Konstruksi: Publikasi Ilmu Teknik, Perencanaan Tata Ruang dan Teknik Sipil*, vol. 2, no. 1, pp. 30-41, 2024.
- [2] S. Duffley and P. McCole, "Extending customer relationship management into a social context," *The Service Industries Journal*, vol. 35, no. 11-12, pp. 591-610, 2015.
- [3] Yulianto, S., Wijaya, D. P., and Hermawati, E., "Aplikasi Berbasis Dataset E-commerce Untuk Prediksi Kenikmatan Menggunakan Algoritma Naive Bayes, Xgboost Dan Similarity Based Feature Selection," *eProceedings of Applied Science*, vol. 6, no. 2, 2020.
- [4] Zhang, T., "Prediction and clustering of bank customer churn based on xgboost and k-means," *BCP Business & Management*, 2022.
- [5] Shrestha, S. M., and Shakya, A., "A customer churn prediction model using XGBoost for the telecommunication industry in Nepal," *Procedia Computer Science*, vol. 215, pp. 652-661, 2022.
- [6] Khamilchi, F. I., Zaim, D., Khalifa, K., 2019. A new model based on global hybridization of machine learning techniques for "customer churn prediction", in: 2019 Third International Conference on Intelligent Computing in Data Sciences (ICDS), IEEE, pp. 1-4.
- [7] Senthan, P., Rathnayaka, R., Kulkarni, S., Kumar, B., 2021. Development of churn prediction model using xgboost-telecommunication industry in sri lanka, in: 2021 IEEE International Conference on Electronics and Mechatronics Conference (IEMTRONICS), IEEE, pp. 1-7.
- [8] Sari, R. P., Febrinyanto, F., and Adi, A. C., "Analysis implementation of the ensemble algorithm in predicting customer churn in telco data: A comparative study," *Informatika*, vol. 47, no. 7, 2023.
- [9] Y. Xie, X. Li, E. W. T. Ng, and W. Ying, "Customer churn prediction using improved balanced random forests," *Expert Syst Appl*, vol. 36, no. 3 PART 1, pp. 5445-5449, 2009, doi:10.1016/j.eswa.2008.06.121
- [10] J. Xiao, G. Tang, C. He, and Z. Bing, "One-Step Classifier Ensemble Model for Customer Churn Prediction With Imbalance Class," *Advances in Intelligent Systems and Computing*, vol. 281, no. January, pp. 843-854, 2014, doi:10.1007/978-3-642-55122-2.